

互联网信息服务算法安全自评估报告

（生成合成类-服务提供者）

主体名称	江西皮蛋科技有限公司	统一社会信用代码	91360732MACNH9AN96
算法名称	MOV 智能对话生成算法	算法类型	生成合成类
算法实现功能	智能对话生成：基于第三方已备案大语言模型 API，为用户提供多轮自然语言对话、工具调用等文本生成服务		
算法使用场景	MOV AI App（Android）内智能对话、工具调用、能力市场		
算法上线情况	☐ 已上线，时间：正在开发阶段 ☒ 未上线，正在内测阶段 ☐ 未上线，		
自评估时间	2026 年 8 月 27 日	报告撰写时间	2026 年 8 月 27 日
算法基本情况	本算法为智能对话生成算法，以 API 接入已完成国家备案的第三方大语言模型（DeepSeek、GLM、Kimi 等），不自训模型。自有层负责对话编排、本地工具调用编排、生成内容安全过滤与防幻觉校验，输出文本对话内容并显著标识 AI 生成。		
算法备案类型	☒ 算法未备案 ☐ 算法已备案，备案编号： ☐ 备案已注销，备案编号： ☐ 其他		
拟公示内容	见附件《拟公示算法机制机理内容》		
落实主体责任基本情况	“江西皮蛋科技有限公司”落实算法安全主体责任基本情况（附件）		

评估算法 描述	1.算法简介：以 API 接入第三方已备案大语言模型、自有编排层负责对话与工具调用编排的对话生成算法；2.应用范围：MOV AI App (Android)；3.服务群体：社会公众（C 端，不面向 14 周岁以下儿童）；4.技术服务频次：用户触发式实时调用；5.软硬件设施及部署位置：Android 客户端（Kotlin 开发），服务端 Node.js 服务与静态站点部署于腾讯云（中国大陆境内），第三方大模型由其运营方部署；6.自评估机制：上线前自评估 + 每半年定期自评估（见附件 2《算法安全自评估制度》）。 1.算法简介 2.应用范围 3.服务群体 4.技术服务频次 5.软硬件设施及部署位置 6.其他)		
评估算法 风险描述	1.算法滥用风险：用户诱导模型生成违法违规、不良信息内容；2.算法被恶意利用风险：提示词注入攻击、越权工具调用；3.算法漏洞风险：第三方模型输出不可控（幻觉、不当内容）；4.个人信息风险：对话内容含个人信息时的传输与存储风险。针对上述风险均已建立对应防控机制（见本报告第四章），残余风险低、总体可控。 1. 算法滥用风险 2. 算法被恶意利用风险 3. 算法漏洞风险 4.违法和不良信息生成风险 5.违法和不良信息存储风险 6.违法和不良信息传播扩散风险 7.数据和用户信息泄露风险 8.其他违法违规风险)		
真实性 声明	我方承诺： 提供的材料准确、真实、合法、有效，并愿为此承担 有关法律责任。		
算法安全 负责人	王阳	联系电话	17679333556



一、算法情况

（一）算法流程

用户输入（文本）→①客户端对话编排（上下文组装、记忆与画像注入、系统提示词定型）→②内容安全前置过滤→③第三方已备案大语言模型 API 生成（DeepSeek / GLM / Kimi, HTTPS 加密传输）→④工具调用编排（可选节点：模型输出经权限分级与审批机制调用本地工具，工具结果回注模型继续生成）→⑤生成内容后置过滤 + 防凭空声称校验→⑥客户端展示（AI 生成内容显著标识）。

（二）算法数据

输入数据：用户输入文本（中文为主，可含英文）；拍照 OCR 场景下用户主动提供的图片在设备端本地识别为文本后进入对话，图片本身不上传。

训练数据：无。本算法不自行训练模型，不涉及训练数据的采集、清洗与使用。

语种与模态：输入文本（中文为主）、输出文本（中文为主）；无跨模态生成。

1. 对话输入类输入数据

用户对话输入文本：模态为文本（中文为主）；不含生物识别信息；内容为用户的提问、指令与上下文信息，以及用户自愿粘贴的文档片段。

2. 对话回复类输出数据

模型生成的对话回复文本：模态为文本（中文为主），无文件输出，经安全过滤后在应用界面展示并附加 AI 生成标识。

3.（无训练数据，本项不适用：本算法接入第三方已备案模型，不自行训练）

（三）算法模型

本算法流程中的模型节点包括外购的第三方大语言模型（统计学习方法）与自有的规则型节点（基于规则或人工定义的方法）。

预处理方法：输入文本的上下文截断（预算口径管理）、敏感凭据受控注入（信息库明文只直填页面、不进入模型上下文）。后处理方法：生成文本安全过滤、防凭空声称校验、AI生成标识附加。

1. 第三方大语言模型（外购技术服务）

基本情况：DeepSeek（深度求索）、GLM（智谱 AI）、Kimi（月之暗面）等大语言模型，均为已完成国家备案的模型服务；模型版本与更新由其运营方管理，我方接入时核验备案状态并每半年复查。模型描述：Transformer 架构生成式语言模型，优化目标、评价指标与指标效果以其运营方公示为准；更新迭代策略：跟随第三方版本，我方持续跟踪其备案有效性。

自有规则型节点

对话编排器（上下文窗口管理、记忆注入规则）、内容安全过滤器（规则匹配）、防凭空声称校验器（规则型校验）、工具调用权限分级与审批器（规则引擎）。均为基于规则的人工定义方法，无统计学习成分。

（四）干预策略

本算法设置的机制性干预节点如下（数据预处理与结果后处理均已包含）。

1. 内容安全前置/后置过滤（预处理和后处理）

策略形式：自动（规则库匹配）。策略目标：拦截违法违规与不良信息的输入与输出。生效时间：全时段。影响范围：全部对话请求与回复。策略依据：《网络信息内容生态治理规定》等法规要求。策略来源：人工制定规则库并持续更新，非数据挖掘生成。预计失效时间：长期有效，随法规与风险态势迭代。

补充策略一——工具调用权限分级与安装审批（自动+人工）：敏感能力（读取凭据/支付/身份）默认拒绝；第三方能力先审后发、人工审核上架。目标：防越权调用与恶意能力安装。

补充策略二——防凭空声称校验（自动）：对“声称已完成但无实际工具调用”的输出进行校验与提示，降低模型幻觉误导。

二、服务提供情况

本算法通过 MOV AI App（Android）直接向社会公众提供智能对话生成服务。

（一）服务方式

1. 服务方式简介

服务名称：MOV AI 智能助手对话服务。访问方式：Android 客户端内对话界面，用户触发式实时调用，无批量处理、无 API 对外开放。服务对象：社会公众（C 端用户），不面向 14 周岁以下儿童。服务频度：按用户会话实时调用，峰值以实际用户量为准。

2. 算法在服务提供中的应用情况

数据来源与形态：用户对话输入文本；无训练数据（不自训模型）。算法更新频率：自有编排层随应用版本更新；第三方模型版本由其运营方更

新，我方跟踪备案状态。中间结果共享情况：工具调用记录等中间结果仅存储于用户设备本地，不与其他服务或应用共享；对话内容仅传输至第三方已备案大模型 API 用于生成回复（不含账号信息）。

三、风险研判

（一）算法滥用

存在用户通过精心构造的输入诱导模型生成违法违规、不良信息内容（涉政有害、淫秽色情、虚假信息等）的潜在风险。影响分析：MOV 为闭域对话应用，生成内容仅对话用户本人可见、无公开传播渠道，滥用影响限于单用户会话范围；已通过前置过滤、后置过滤、第三方模型自身安全能力三层拦截，残余风险低。

（二）算法漏洞

第三方大模型存在固有输出不可控性（幻觉、偏见、不当内容），自有编排层可能存在上下文污染。影响分析：幻觉可能导致用户获得错误信息；本算法不涉及金融、医疗等高风险决策场景，且已通过防凭空声称校验与 AI 生成标识（明示“内容由 AI 生成，请注意甄别重要信息”）缓解，风险可控。

（三）算法恶意利用

存在提示词注入攻击（诱导模型忽略安全指令）与越权工具调用（诱导模型执行敏感操作）的潜在风险。影响分析：越权调用可能影响用户设备端文件与数据；已通过工具权限分级（敏感能力默认拒绝）、安装审批、调用审批文案明示三重机制防控，残余风险低。

（二）其他风险

（三）对话内容可能含用户个人信息，传输至第三方模型存在泄露风险。已通过最小化传输（不含账号信息）、HTTPS 加密传输、信息库凭据不进入模型上下文等措施防控。

四、风险防控情况

（一）风险防范机制建设

1. 算法机制机理审核

详见附件：“【主体名称】”落实算法安全主体责任基本情况。

补充：新工具/能力上架前人工审核其描述与来源（先审后发），审核记录留档备查。

该机制对第三章（一）算法滥用、（三）算法恶意利用风险有效。

2. 算法安全评估监测

详见附件：“【主体名称】”落实算法安全主体责任基本情况。

补充：上线前自评估 + 每半年定期自评估制度（附件 2《算法安全自评估制度》）；能力市场人工审核执行记录可查。

该机制对第三章全部四类风险有效。

3. 算法安全事件应急处置

详见附件：“【主体名称】”落实算法安全主体责任基本情况。

补充：附件 4《算法安全事件应急处置预案》——三级事件分级、一般事件 24 小时处置、较大及以上立即熔断下线、按规定向主管部门报告、复盘整改闭环。

该机制对第三章全部四类风险有效。

（二）用户权益保护

1. 用户个人信息保护

符合《个人信息保护法》等法律法规要求：《隐私政策》（V1.1）已公示收集范围与用途；注册登录收集手机号（最小必要）；对话内容传输至第三方已备案大模型 API 系提供服务所必需，不含账号信息，HTTPS 加密传输，不会造成个人信息泄露；用户可删除对话记录、申请注销账号（核实身份后 15 个工作日内处理）。不涉及编辑他人个人信息场景。

该机制对第三章（四）其他风险（个人信息泄露）有效。

2. 其他权益保护

遵循《互联网信息服务算法推荐管理规定》《互联网信息服务深度合成管理规定》《生成式人工智能服务管理暂行办法》：AI 生成内容已显著标识；不面向 14 周岁以下儿童提供服务；已建立用户查询、更正、删除、注销响应机制（隐私政策第七条约定的渠道与承诺时限）。

该机制对第三章（一）（二）类风险有效。

（三）模型安全保障

本算法接入的第三方模型备案准入与自有层安全机制如下。

1. 第三方模型备案准入保障机制

机制：仅接入已完成国家备案的大语言模型，接入前人工核验备案状态，每半年复查并留档。来源：《生成式人工智能服务管理暂行办法》及备案管理要求（人工流程）。目的：从源头保证生成能力合规。效果：当前接入的 DeepSeek、GLM、Kimi 均为已备案模型。效果评估方法：每半年复查备案状态并留存核查记录。

该机制对第三章（一）（二）类风险有效。

自有层安全机制：提示词防护（系统提示词定型、会话前缀恒定）、工具权限分级（敏感能力默认拒绝）、防凭空声称校验。本算法不自训模型，不涉及数据投毒/模型投毒的直接风险；第三方模型的相应保障由其运营方负责并受其备案约束。

2. 自有层安全机制

（四）数据安全防护

本算法无训练数据（不自行训练模型）。服务数据保护：对话记录默认存储于用户设备本地；账号数据（手机号、登录凭证）存储于腾讯云（中国大陆境内），加密存储、日志脱敏展示、口令+令牌双重鉴权；开发测试使用脱敏或构造数据，不使用生产环境真实用户数据。与第三方共享仅限对话内容至已备案大模型 API（HTTPS 加密、不含账号信息），共享合法、正当、必要。

五、安全评估结论

经评估，本算法安全风险总体可控：已建立覆盖算法全生命周期的安全管理制度（附件 2~6），技术层面形成“第三方已备案模型准入 + 前后内容过滤 + 权限分级审批 + 防幻觉校验 + AI 生成标识”的防控组合，安全策略与安全风险相匹配。安全自评估结论：通过。



六、其他应当说明的相关情况

本算法接入的第三方大语言模型均为已完成国家备案的模型服务，其备案编号以各运营方公示为准。